

Formation ICAM: DATA SCIENCE

« *VAE for Spike Train Analyses* »:

Classement de profils d'activités de neurones biologiques par apprentissage profond de type auto-encodeur (VAE)

Kiné Diagne DIOP GUEYE

19/06/2026



Sommaire

1. Contexte du stage



Laboratoire de
recherche
fondamentale
en Neuroscience



Université
de Strasbourg



2. Défis en science de données & Solutions

Intégration

Visualisation

Analyse

Industrialisation

Notebook



1. Contexte du stage



Université
de Strasbourg




Laboratoire de recherche fondamentale en neurosciences
Comment se comporte l'activité électrique des neurones du cerveau
dans des situations de stress?

Enregistrement de l'activité
de 100 à 1000 neurones



M.E.A



1. Contexte du stage



Université
de Strasbourg



Laboratoire de recherche fondamentale en neurosciences
Comment se comporte l'activité électrique des neurones du cerveau
dans des situations de stress?

Enregistrement de l'activité
de 100 à 1000 neurones




M.E.A

Neurone #1




mV / sec.

Neurone #1



event / temps.



Comment classer automatiquement
les « spike trains »?

Peut-on détecter des **anomalies/ des changements** dans les spike trains au
cours du temps?

1. Contexte du stage

Raster-Plot Spike Train



DATaset

Neurone #1	0	0	1	0	0	0	1	0	0	1
Neurone #2	1	0	0	0	0	0	0	1	0	0
Neurone #3	0	0	0	1	0	0	0	0	0	0
Neurone #4	0	0	0	0	1	0	0	1	0	0
Neurone #5	0	0	0	1	0	0	0	1	0	1
Neurone #6	0	0	0	1	0	0	0	0	1	0
Neurone #7	1	0	0	0	0	0	0	0	1	0


Une cellule du tableau = 1 unité de temps

1 = 1 spike = 1 potentiel d'action

0 = pas de spike; silence

1. Contexte du stage

Raster-Plot Spike Train



Défis DATA science

Intégration

Analyse


Détection automatique d'anomalies dans des « spike trains » à l'aide d'un algorithme d'apprentissage profond

Visualisation

Industrialisation

2. Défis en science de données & Solutions

2.1. Intégration



Comment visualiser ces données?

2. Défis en science de données & Solutions

2.2. Visualisation

Pouvoir visualiser
tous les « spike
trains » du dataset


DATAset-100n-5k-#31A

3 classes de 33 neurones; 1 neurone **Atypique**


Données de synthèse :

reproduit un enregistrement, avec des comportements de neurones par **classes** identifiées; génération aléatoire

Distribution ISI




Sporadique




ISI Variable
(2 - 5 Hz)

Tonique



ISI constante
(10 - 20 Hz)

Burst



ISI Inter/Intra-burst
(50 - 100 Hz)

Atypique



Loi Poisson $P(X=k) = \frac{\lambda^k e^{-\lambda}}{k!}$

Comment visualiser la distribution des spike trains?


2. Défis en science de données & Solutions

2.2. Visualisation

DATAset01-100n-5k-#31A

Pouvoir visualiser
tous les « spike
trains » du dataset

matplotlib



Burst

Tonique

Atypique

Sporadique

Comment naviguer dans les données pour retrouver les spike trains d'intérêt?


2. Défis en science de données & Solutions

2.2. Visualisation

DATAset01-100n-5k-#31A

Pouvoir visualiser
tous les « spike
trains » du dataset

bok^{eh}



Comment analyser ce dataset?

2. Défis en science de données & Solutions

2.3. Analyse

Analyse
Exploratoire
des
Données



DATASET	Moyenne nbr P.A / Spike train	Ecart-type Variabilité	Persistence
	mean_activity	std_activity	persistence
neurone01	0.02430	0.153980	0.000000
neurone02	0.02530	0.157036	0.000000
neurone03	0.02494	0.155944	0.000000
neurone04	0.02458	0.154843	0.000000
neurone05	0.02452	0.154658	0.000000
...	---	---	---

Chaque neurone est résumé par 3 caractéristiques:

Moyenne: La fréquence moyenne de *spiking* de chaque neurone (Hz).

Ecart-type: Mesure de la régularité du *spiking*.

Persistence: Probabilité qu'un neurone reste actif à l'instant t+1 sachant qu'il est actif à l'instant t.

Est-ce que le dataset contient des regroupements possibles de données? 11

2. Défis en science de données & Solutions

2.3. Analyse

DATAset01-100n-5k-#31A


Groupes
possibles?

Moyenne
Ecart-type
Persistance




Cluster:
K-mean
t-SNE
UMAP


K-mean / PCA



t-SNE



UMAP



X Neurone #31 Atypique

Dataset contient bien 3 groupes de données

Comment classer les « spike trains » en conservant la temporalité?

2. Défis en science de données & Solutions

2.3. Analyse


Auto-encodeur variationnel

Classification automatique apprentissage non supervisé

Donnée non-balancées binaires séquencées

VAE: Variational Autoencoder

Mécanisme Attention



Quels encodeurs séparent / groupent mieux les spikes trains?

2. Défis en science de données & Solutions

2.3. Analyse DATaset01-100n-5k-#31A

Test 1

VAE

Self-Attention

 Keras

Encodeur : réseau ANN


50 pts (Temps)

→ Conv1D

→ MaxPooling1D

→ Self – Attention

→ Espace Latent (2D)



Est-ce plus performant avec multi?

2. Défis en science de données & Solutions

2.3. Analyse DATaset01-100n-5k-#31A

Test 2

VAE


Multi-Attention



Encodeur : réseau ANN

50 pts (Temps)

- Conv1D
- MaxPooling1D
- Multi
- HeadAttention
- Espace Latent (2D)



Quels encodeurs séparent / groupent mieux les spikes trains?

2. Défis en science de données & Solutions


2.3. Analyse DATaset01-100n-5k-#31A

Encodeur : Comparaison CNN vs SNN


Les neurones à impulsions (SNN) sont des neurones artificiels développés récemment pour travailler avec des séries temporelles binaires

<https://omkarska.medium.com/comparing-spiking-neural-networks-snns-and-convolutional-neural-networks-cnns-fe0538196895>



CNN



ANN « standard »



SNN pour les données temporelles



Encodage Binaire des données




Tutorial

Title

Tutorial 1

Spike Encoding with snnTorch




SNN « impulsion » meilleur pour détecter les dynamiques temporelles et serait moins énergivore

2. Défis en science de données & Solutions

2.3. Analyse DATASET01-100n-5k-#31A

Encodeur :
VAE SNN

Entrée : les données séquentées



Encodeur : réseau ANN

0	0	1	0
1	0	0	0
0	0	0	1
0	0	0	0

Encodage Binaire des données pas nécessaire

Nos données sont directement
binaires / temporelle




Espace Latent 2D

Encodage Binaire des données



Tutorial	Title
Tutorial 1	Spike Encoding with snnTorch



Peut-on classifier automatiquement les « spike trains » avec un VAE SNN?

Peut-on détecter des **anomalies**/ **des changements** dans les spikes trains au cours du temps avec des VAE SNN?

2. Défis en science de données & Solutions

2.3. Analyse DATAs01-100n-5k-#31A

Test 3


VAE

Neurones à
Impulsions

snnTorch

Encodeur : réseau SNN-VAE

50 pts (Temps)
→ Linear(128)
→ **SNN Leaky(LIF)**
→ **Espace Latent (2D)**



Quels encodeurs séparent / groupent mieux les spikes trains?



2. Défis en science de données & Solutions

2.3. Analyse DATaset01/02/03 (100n-5k-#31A)



Quelles approches choisir?

- VAE-self attention
- VAE-multi attention
- VAE-SNN



Ratio (Distance/Taille)	VAE Self attention	VAE Multi attention	VAE SNN impulsion
Dataset01	0,88	8,15	11,33
Dataset02	0,96	11,00	15,00
Dataset03	0,63	3,00	34,29
Moyenne	0,82	7,38	20,21
SD	0,14	3,31	10,07

R = Ratio de distance pour neurone atypique (#31, X) avec son plus proche voisin de cluster

Conclusion: L'approche VAE-SNN isole mieux le neurone atypique

2. Défis en science de données & Solutions

2.3. Analyse DATaset01/02/03 (100n-5k-#31A)



Quelles approches choisir?

- VAE-self attention
- VAE-multi attention
- VAE-SNN

```
from codecarbon import EmissionsTracker
```

Consommation énergétique (Wh)	VAE Self attention	VAE Multi attention	VAE SNN impulsion	Diminution énergie multi vs SNN (%)
Dataset01	0,95	7,85	3,12	60%
Dataset02	0,96	7,04	3,11	56%
Dataset03	1,00	6,87	3,00	56%
Moyenne	0,97	7,25	3,08	58%
SD	0,03	0,53	0,07	

Consommation énergétique par jeu de données

Conclusion: VAE Self consomme moins d'énergie


2. Défis en science de données & Solutions

2.3. Analyse DATAs0100n-5k-#31A)

Quelles approches choisir?


VAE-self attention
VAE-multi attention
VAE-SNN

VAE Self-attention




- Energivore
- Discriminant

VAE Multi-attention



+ Energivore
- Discriminant

VAE SNN impulsion



+ Energivore
+ Discriminant

Conclusion: VAE Self pour détection préliminaire / SNN pour plus d'analyse

2. Défis en science de données & Solutions

2.3. Analyse DATAs01


Entraînement sur 3 époques

Quelles approches choisir?

VAE-
self attention
VAE-
multi attention
VAE-
SNN


VAE Self-attention

VAE Latent Space: Neural Population Classification




VAE Multi-attention

Latent Space (PyTorch + Batch Training)



VAE SNN impulsion

Espace Latent snnTorch (Spiking VAE)



2. Défis en science de données & Solutions

2.3. Analyse DATAs01


Entraînement sur 3 époques




Quelles approches choisir?

- VAE-self attention
- VAE-multi attention
- VAE-SNN


VAE Self-attention



VAE Multi-attention



VAE SNN impulsion



Energie(Wh)	VAE Self attention		VAE Multi		VAE impulsion	
	30 époques	3 époques	30 époques	3 époques	30 époques	3 époques
Dataset01	0,95	0,10	7,85	1,06	3,12	0,38
Diminution de la consommation d'énergie (%)	89.24%		86.36 %		87.69 %	

2. Défis en science de données & Solutions


2.4. Industrialisation

- ✓ Disponible 24/24h
- ✓ Interactive
- ✓ Réutilisable


Développer une Wep-app



Panel



Visualisation



Analyse

2. Défis en science de données & Solutions

2.4. Industrialisation


Big-DATASET01-1000n-50k

Peut-on utiliser
ces approches
pour des lots de
données
massifs?

>
SSH

IASTRO.LBGI.FR

Plateforme
bigEST 






2. Défis en science de données & Solutions

2.4. Industrialisation

Big-DATaset01-1000n-50k


Peut-on utiliser
ces approches
pour des lots de
données
massifs?



Plateforme
bigEST 



I-astro Virtual Machine
16-CPU; 45Go-GPU; 62 Go-RAM

VAE multi-attention



Cela reste encore a améliorer

2. Défis en science de données & Solutions

2.4. Industrialisation



Big-DATaset01-1000n-50k-5%Atypique versus 95% Toniques

Peut-on déceler
des domaines de
fréquences
atypique de
faible densité ?

>
SSH

IASTRO.LBGI.FR

Plateforme
bigEST



2. Défis en science de données & Solutions

2.4. Industrialisation



Big-DATaset01-1000n-50k-5%Atypique versus 95% Toniques

Peut-on détecter des domaines de fréquences atypique de faible densité ?

>
SSH


IASTRO.LBGI.FR

Plateforme
bigEST



Optimisation de la Fonction de Perte



```
# Perte corrigée (MSE mean + KLD avec poids beta de 0.005)
loss_recon = F.mse_loss(recon, data_batch, reduction='mean')
loss_kld = -0.5 * torch.mean(1 + logvar - mu.pow(2) - logvar.exp())
loss = loss_recon + 0.0005 * loss_kld
```



Essais concluant avec un VAE-SNN modifié

3. Conclusion

Données



Intégration



Visualisation



Notebook



Analyse



Industrialisation



SSH



Panel

4. Perspectives

Développement d'un pipeline d'analyse pour quantifier les séries temporelles

Neurosciences

- Détection de neurones atypiques
- Identification de changements de comportement

Données météorologiques

- Détection d'événements rares :
 - Canicules
 - Tempêtes
 - Précipitations extrêmes
- Analyse automatique de séries temporelles de capteurs

Fraude bancaire

- Détection de transactions atypiques
- Identification de comportements suspects en temps réel
- Analyse de séquences d'opérations financières

Données séquencées → Espace latent → Détection d'anomalies / événements rares / classification

Je vous remercie pour votre attention