



# DOSSIER PROFESSIONNEL (DP)

*Nom de naissance* ▶ DIOP GUEYE  
*Nom d'usage* ▶  
*Prénom* ▶ Kiné Diagne  
*Adresse* ▶ Rue du Général Zimmer, Strasbourg, 6700

## Titre professionnel visé

Diplôme Data Science niveau master

### MODALITÉ D'ACCÈS :

- ☒ Parcours de formation
- ☐ Validation des Acquis de l'Expérience (VAE)

# DOSSIER PROFESSIONNEL <sup>(DP)</sup>

## Présentation du dossier

Le dossier professionnel (DP) constitue un élément du système de validation du titre professionnel. **Ce titre est délivré par le Ministère chargé de l'emploi.**

Le DP appartient au candidat. Il le conserve, l'actualise durant son parcours et le présente **obligatoirement à chaque session d'examen.**

Pour rédiger le DP, le candidat peut être aidé par un formateur ou par un accompagnateur VAE.

Il est consulté par le jury au moment de la session d'examen.

### Pour prendre sa décision, le jury dispose :

1. des résultats de la mise en situation professionnelle complétés, éventuellement, du questionnaire professionnel ou de l'entretien professionnel ou de l'entretien technique ou du questionnement à partir de productions.
2. du **Dossier Professionnel** (DP) dans lequel le candidat a consigné les preuves de sa pratique professionnelle
3. des résultats des évaluations passées en cours de formation lorsque le candidat évalué est issu d'un parcours de formation
4. de l'entretien final (dans le cadre de la session titre).

*[Arrêté du 22 décembre 2015, relatif aux conditions de délivrance des titres professionnels  
du ministère chargé de l'Emploi]*

### Ce dossier comporte :

- pour chaque activité-type du titre visé, un à trois exemples de pratique professionnelle ;
- un tableau à renseigner si le candidat souhaite porter à la connaissance du jury la détention d'un titre, d'un diplôme, d'un certificat de qualification professionnelle (CQP) ou des attestations de formation ;
- une déclaration sur l'honneur à compléter et à signer ;
- des documents illustrant la pratique professionnelle du candidat (facultatif)
- des annexes, si nécessaire.

---

## DOSSIER PROFESSIONNEL <sup>(DP)</sup>

---

---

---

*Pour compléter ce dossier, le candidat dispose d'un site web en accès libre sur le site.*

▲ <http://travail-emploi.gouv.fr/titres-professionnels>

# DOSSIER PROFESSIONNEL <sup>(DP)</sup>

## Sommaire

### Exemples de pratique professionnelle

Les exemples qui suivent sont issus de mon travail de stage, réalisé dans le laboratoire du CNRS : Inci (Institut des neurosciences cellulaire et intégratives, UPR3212) dans l'équipe : « Modulation peptidique des émotions » dans le groupe de recherche de Monsieur PETITJEAN : « Perceptio : investigation fonctionnelle et modélisation du traitement de l'information sensorielle dans les réseaux de neurones »

### Intégration des données

p. 9

► Intégration et conversion de données brutes provenant d'un système d'acquisition MultiElectrode Array (Format HDF5 / MEA)

p. 9

► Intégration et restructuration de matrices scientifiques (Format .MAT / MATLAB)

p. 12

► Création de jeux de données (datasets) synthétiques pour tester des algorithmes d'analyse

p. 16

### Analyse des données

p. 20

► Exploration des datasets

p. 20

► Analyse comparative de clustering et réduction de dimension (DBSCAN, t-SNE, UMAP, K-NN)

p. 26

► Modélisation générative par Deep Learning (VAE & Transformers) avec Keras

p. 32

### Visualisation

p. 39

► Visualisation exploratoire avec Matplotlib

P. 39

► Visualisation exploratoire interactive avec Python (Bokeh)

P. 42

### Industrialisation

p. 46

---

## DOSSIER PROFESSIONNEL <sup>(DP)</sup>

---

---

|                                                                                |    |    |
|--------------------------------------------------------------------------------|----|----|
| ▶ D'un VAE en Deep Learning standard à un VAE à Impulsion                      | p. | 46 |
| ▶ Mise en place d'un explorateur PANEL sur Hugging face (application NEURO IA) | p. | 47 |
| ▶ Mise en place d'un environnement de calcul distant (Machine Virtuelle & SSH) | p. | 52 |
| <b>Titres, diplômes, CQP, attestations de formation</b> <i>(facultatif)</i>    | p. |    |
| <b>Déclaration sur l'honneur</b>                                               | p. |    |
| <b>Documents illustrant la pratique professionnelle</b> <i>(facultatif)</i>    | p. |    |
| <b>Annexes</b> <i>(Si le RC le prévoit) Code</i>                               | p. | 60 |

## EXEMPLES DE PRATIQUE PROFESSIONNELLE

### Remerciements

Je tiens à exprimer ma profonde gratitude aux personnes qui m'ont accompagné et soutenu tout au long de la réalisation de ce projet :

Tout d'abord, je remercie chaleureusement l'ensemble de **l'équipe Modulation peptidique des émotions** de l'INCI au CNRS pour son accueil et pour m'avoir permis d'évoluer dans un environnement de recherche stimulant et à la pointe de la technologie.

Je tiens à remercier tout particulièrement mon tuteur, monsieur PETITJEAN Hugues, pour sa disponibilité, sa patience et la qualité de son encadrement. Ses conseils avisés et son expertise en neurosciences et en intelligence artificielle m'ont permis de mener à bien ce stage.

Enfin, je remercie toutes les personnes qui, de près ou de loin, ont contribué par leurs échanges et leur bienveillance à la réussite de ce travail.

## Introduction et Contexte

Ce stage a été effectué au sein du laboratoire INCI (Institut des Neurosciences Cellulaires et Intégratives) du CNRS, dans l'équipe **Modulation peptidiques des émotions** dirigée par Alexandre Charlet, et j'ai travaillé dans le groupe de recherche de Hugues Petitjean. Ce groupe de recherche travaille sur la quantification de l'activité électrique des neurones du cerveau de rongeurs et la modélisation du traitement de l'information sensorielle dans différentes tâches cognitives.

Mon travail de DATA Scientist a été de développer une solution de visualisation et d'analyse de leurs données issues d'enregistrements de l'activité électrique des neurones. Il s'agit de série de lots de série temporelles comprenant 100 à 1000 enregistrements de 30-60 minutes à une fréquence d'acquisition de 20kHz. Ces séries temporelles sont prétraitées pour être stockées dans des tableaux de données. Chaque potentiel d'action, le moment où le neurone biologique intègre et envoie un signal est codé par **1** ; et lorsqu'il est silencieux par un **0**. Cela constitue des lots de données massifs ; déséquilibré de série-temporelles.

Pour les biologistes il est important de classer ces séries temporelles en classe particulière, permettant de conclure sur l'état de fonctionnement du cerveau lors des tâches cognitives. La détection de séries atypiques peut être un indicateur de développement de pathologie ou de l'effet d'un traitement pharmacologique. Dans ce contexte la **thématique de stage de DATA Science a été de développer une méthode non supervisée de regroupement et d'exploration de séries temporelles neuronales permettant d'identifier automatiquement des groupes de comportements similaires ainsi que des observations atypiques dans des lots de données de 100 à 1000 enregistrements de neurones biologiques.**

### Défi technique

Le défi technique repose sur plusieurs obstacles identifiés :

- L'impossibilité de l'analyse visuelle : À l'œil nu, il est impossible de trier ou de classer les milliers de données simultanément. Les systèmes d'acquisition actuels ne proposent pas de tri automatisé en temps réel.
- Les limites des méthodes multivariées classiques : Si les méthodes de classement standard existent, elles ne sont pas adaptées aux données séquencées et temporelles. Elles traitent souvent chaque point de donnée comme indépendant, perdant ainsi l'information biologique essentielle contenue dans la dynamique du signal.

## DOSSIER PROFESSIONNEL <sup>(DP)</sup>

- Les lots de données sont séquencés (série-temporelle) et déséquilibrés avec un ratio asymétrique d'environ 95 % de 0 pour seulement 5 % de 1.

Réaliser un classement automatisé ou une détection d'anomalies sur des séries temporelles non-balancées est un défi en science des données. Les algorithmes classiques ont tendance à ignorer le signal rare (le 1) au profit de la classe majoritaire (le 0). Les méthodes de prédiction classiques comme l'ARIMA ou la SARIMA ne sont pas applicables ici. Ces modèles sont conçus pour prédire des valeurs futures dans le temps, alors que notre objectif est de segmenter/regrouper (clustering) et de caractériser des comportements existants (identifier des types de neurones).

**Solution : un Variational Autoencoder (VAE) a été utilisé pour apprendre une représentation latente compacte des séries temporelles. Cette représentation a ensuite servi de base à des analyses de regroupement et de détection d'observations atypiques.**

Pour mettre au point la solution, j'ai travaillé avec deux jeux de données synthétiques de 50 000 lignes et contenant 101 colonnes simulant l'activité de 100 neurones en fonction du temps (Fréquence d'acquisition pour 1 seconde = 1000 points/ligne). Cette approche mime le comportement de l'activité de neurones enregistrés à l'aide de la technique du Multi Electrode Array (MEA). Cette technique permet l'enregistrement d'un grand nombre de neurones en même temps depuis des préparations biologiques (cultures cellulaires, don de tissus) et de tester en temps réel des médicaments pouvant altérer l'activité électrique des neurones.

Une fois le VAE testé, j'ai travaillé au déploiement de ma solution sur différents supports pour la rendre accessible facilement aux chercheurs utilisateurs.

|                      | Dataset_neurone_100 | Dataset_neurone_100_anomal |
|----------------------|---------------------|----------------------------|
| Nombre de neurones   | 100                 | 100                        |
| Enregistrement       | 50000               | 50000                      |
| Temps (milliseconde) | 50000               | 50000                      |



## DOSSIER PROFESSIONNEL (DP)

|                  |                        |                        |
|------------------|------------------------|------------------------|
| Temps (second)   | 50                     | 50                     |
| Shape du dataset | (50.000, 100)          | (50.000, 100)          |
| Classe 1         | neurone1 à neurone30   | neurone1 à neurone30   |
| Classe 2         | neurone31 à neurone60  | neurone32 à neurone60  |
| Classe 3         | neurone61 à neurone100 | neurone61 à neurone100 |
| Anomalie         | Pas d'anomalie         | neurone31              |

Tableau expliquant la composition des datasets.

### Activité-type 1 Intégration de données

**Exemple n°1** ► Intégration et conversion de données brutes provenant d'un système d'acquisition MultiElectrode Array (Format HDF5 / MEA)

#### 1. Décrivez les tâches ou opérations que vous avez effectuées, et dans quelles conditions :

Dans le cadre de mon projet portant sur l'analyse de signaux neuronaux, j'ai été amené à intégrer des données brutes issues d'un système d'acquisition de type MEA (*Multi-Electrode Array*). Ces dispositifs permettent d'enregistrer simultanément l'activité électrique de plusieurs neurones, générant ainsi des volumes de données importants et complexes à manipuler.

Les données étaient stockées au format HDF5 (*Hierarchical Data Format version 5*), un format que je ne maîtrisais pas initialement. Afin d'éviter tout risque d'altération des données biologiques réelles, nous avons d'abord réalisé une phase d'apprentissage technique à partir d'un jeu de données public : le dataset MNIST disponible au format HDF5 sur kaggle [https://www.kaggle.com/datasets/benedictwilkinsai/mnist-hd5f?utm\\_source=chatgpt.com&select=train.hdf5](https://www.kaggle.com/datasets/benedictwilkinsai/mnist-hd5f?utm_source=chatgpt.com&select=train.hdf5). Cette étape m'a permis de comprendre la structure interne des fichiers HDF5, notamment l'organisation en groupes (*Groups*), en ensembles de données (*Datasets*), ainsi que la gestion des métadonnées associées.

Le format HDF5 est particulièrement adapté au stockage de grandes quantités de données numériques grâce à plusieurs caractéristiques essentielles :

## 1. Organisation hiérarchique des données

Un fichier HDF5 fonctionne comme une arborescence de dossiers. Il peut contenir des *Groups* (comparables à des répertoires) et des *Datasets* (semblables à des tableaux NumPy), permettant une structuration claire et efficace des données.

## 2. Performance et rapidité d'accès

Ce format est optimisé pour la lecture et l'écriture de volumes massifs de données. Contrairement à un fichier CSV, il permet d'accéder uniquement à une portion spécifique des données sans charger l'ensemble du fichier en mémoire, ce qui représente un avantage majeur pour les données issues des systèmes MEA.

## 3. Gestion des métadonnées

Le format HDF5 est auto-descriptif : il permet d'associer directement des informations contextuelles aux données enregistrées, telles que la température d'acquisition, la fréquence d'échantillonnage ou encore les paramètres expérimentaux.

En neurosciences, ce format est largement utilisé, car les systèmes d'acquisition génèrent des milliers de points de mesure par seconde pour chaque électrode. Un format classique comme le CSV deviendrait rapidement trop volumineux et inefficace. Le HDF5 permet, au contraire, de compresser et d'organiser efficacement ces données tout en facilitant leur exploitation sous Python, notamment grâce à la bibliothèque h5py.

Cette phase préparatoire m'a permis d'acquérir les compétences nécessaires pour manipuler les données issues du système MEA de manière sécurisée et structurée, tout en garantissant l'intégrité des données biologiques utilisées dans le projet.

## 2. Précisez les moyens utilisés :

Environnement Python Colab, H5py, Pandas, Dataset de test (MNIST HDF5), Données machine MEA.

Nom du notebook : integration\_HDF5.ipynb

Lien du notebook :

<https://colab.research.google.com/drive/1Or2Jad6QWLFEdtkRW3BtUrf4Fe7ykQy>

# DOSSIER PROFESSIONNEL <sup>(DP)</sup>

## 3. Avec qui avez-vous travaillé ?

L'ensemble de mon travail a été réalisé durant mon stage, en combinant recherche personnelle et prise d'initiative, réunions de suivi avec mon tuteur, ainsi que des échanges réguliers avec les membres de l'équipe d'accueil. J'ai également sollicité, de manière proactive, mon tuteur et certains collègues afin de surmonter des difficultés techniques spécifiques.

## 4. Contexte

Nom de l'entreprise, organisme ou association ►

**INCI CNRS**

Chantier, atelier, service ► **CNRS**

Période d'exercice ► Du **11/02/202** au **17/06/2026**  
**6**

## 5. Informations complémentaires (facultatif)

### Description du dataset

|                            |                                                   |
|----------------------------|---------------------------------------------------|
| Nom du fichier             | train.hdf5                                        |
| Jeux de données (datasets) | image, label                                      |
| Nombre d'échantillons      | 60 000                                            |
| Forme des images           | 28 × 28 pixels (grayscale)                        |
| Type de données            | image → <u>array numpy 2D</u> (pour chaque image) |
| label                      | entier (0 à 9, la classe de l'image)              |

### Code utilisé

Ce code sert à transformer un fichier HDF5 en un DataFrame pandas afin de pouvoir l'analyser

```
import h5py
import pandas as pd

# Ouvrir le fichier HDF5
with h5py.File("/content/drive/MyDrive/ICAM-Stage-2026-Kine/Data /train.hdf5", 'r') as f:
    print("Jeux de données disponibles :", list(f.keys()))

    # Charger les données
    images = f['image'][:] # toutes les images
    labels = f['label'][:] # toutes les étiquettes

# Créer un DataFrame
df = pd.DataFrame({
    'image': list(images), # chaque ligne = un tableau numpy de l'image
    'label': labels        # chaque ligne = l'étiquette correspondante
})

print(df.head()) # afficher les 5 premières lignes
```

## Activité-type 1 Intégration de données

### Exemple n°2 ► Intégration et restructuration de matrices scientifiques (Format .MAT / MATLAB)

#### 1. Décrivez les tâches ou opérations que vous avez effectuées, et dans quelles conditions :

Dans la continuité de mon travail d'intégration, j'ai également manipulé des jeux de données complexes stockés au format propriétaire .MAT (MATLAB). Ce format est extrêmement répandu dans le domaine de la recherche et du traitement de signaux biologiques. Le défi principal consistait à transformer ces structures matricielles multidimensionnelles, souvent imbriquées, en un format tabulaire (DataFrame) exploitable sous Python.

À l'aide de la bibliothèque scipy.io, j'ai développé un script pour charger les fichiers et explorer les dictionnaires de données MATLAB, tout en filtrant les métadonnées système.

On a mis en place des fonctions de restructuration (opérations de *reshape* et de transposition) pour aligner les différentes variables (profondeur, temps, identifiants des neurones) malgré leurs dimensions hétérogènes

Sur le plan de la modélisation, le dataset fourni ne contient pas les enregistrements temporels continus bruts (raw continuous traces), mais des waveforms (la forme d'onde moyenne des potentiels d'action pour chaque neurone). C'est un grand avantage en termes de nettoyage de données, car cela nous évite l'étape complexe du "spike sorting" (l'algorithme de séparation et d'extraction des signaux individuels à partir du bruit de fond).

---

## DOSSIER PROFESSIONNEL <sup>(DP)</sup>

---

---

Cependant, cette agrégation signifie que nous disposons d'un volume de données très restreint (une seule forme d'onde par neurone). Pour contourner cette limite et pouvoir exploiter toute la puissance du Deep Learning (notamment notre modèle génératif VAE) sans tomber dans le surapprentissage (overfitting), on a mis en place la génération d'un dataset synthétique. Cette approche de Data Augmentation permet de simuler des milliers de variations biologiquement réalistes pour entraîner le modèle de manière robuste.

### 2. Précisez les moyens utilisés :

Environnement Python Colab, Scipy (scipy.io), Numpy, Pandas

Bibliothèque principale: Scipy

Nom des notebooks: test.ipynb

Lien du notebook : <https://colab.research.google.com/drive/1Jd5hwvxUoBD-5YWlx6eZfMEAa4LIO-oY#scrollTo=Rg9MFWPDMRf8>

### 3. Avec qui avez-vous travaillé ?

L'ensemble de mon travail a été réalisé durant mon stage, en combinant recherche personnelle et prise d'initiative, réunions de suivi avec mon tuteur, ainsi que des échanges réguliers avec les membres de l'équipe d'accueil. J'ai également sollicité, de manière proactive, mon tuteur et certains collègues afin de surmonter des difficultés techniques spécifiques.

# DOSSIER PROFESSIONNEL <sup>(DP)</sup>

## 4. Contexte

Nom de l'entreprise, organisme ou association ►

**INCI CNRS**

Chantier, atelier, service

► **CNRS**

Période d'exercice

► Du **11/02/202** au **17/06/2026**  
**6**

### 1. Informations complémentaires (facultatif)

#### Description du dataset

|                       |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         |
|-----------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Nom du fichier        | <u>MergedData.mat</u>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                   |
| Format                | MATLAB v5.0 (MAT-file)                                                                                                                                                                                                                                                                                                                                                                                                                                                                                  |
| Type de données       | Matrices multidimensionnelles et métadonnées scientifiques.                                                                                                                                                                                                                                                                                                                                                                                                                                             |
| Nombre d'échantillons | 246 neurones                                                                                                                                                                                                                                                                                                                                                                                                                                                                                            |
| Contenu principal     | <p>Signaux (Time Series) : Matrices d'activité neuronale (ex: <u>AllResp</u>) représentant la réponse électrique au cours du temps.</p> <ul style="list-style-type: none"><li>• Métadonnées : Variables de profondeur (<u>depth</u>), coordonnées spatiales et indices expérimentaux. Type de structures : Vecteurs : <u>Arrays Numpy</u> 1D (ex: <u>depth</u> → <u>shape</u> (246,)).</li><li>• Matrices : <u>Arrays Numpy</u> 2D (ex: séries temporelles → <u>shape</u> (246, T)).</li></ul> <p> </p> |

## Code utilisé :

Ce code nous permet d'ouvrir un fichier .mat dans in environnement python.

```
import scipy.io
import pandas as pd
import numpy as np

# 1. Load the file
mat_data = scipy.io.loadmat('MergedData.mat')

# 2. Identify keys that are not data (Matlab headers)
ignore_keys = ['__header__', '__version__', '__globals__']

# 3. Dictionary to build the DataFrame
data_dict = {}

# Detect number of neurons (rows)
# We use 'depth' to find the number of neurons
if 'depth' in mat_data:
    depth_array = mat_data['depth']
    # Get the largest dimension (handles both (N,1) and (1,N) and (N,))
    n_neurons = max(depth_array.shape)
else:
    # Fallback just in case
    n_neurons = 246

print(f"Detected {n_neurons} neurons. Processing...")

# 4. Iterate through each variable
for key in mat_data:
    if key in ignore_keys:
        continue

    array = mat_data[key]

    # --- FIX: DATA CLEANING STEP ---
    # If the array is 1D (e.g., shape is (246,)), convert it to 2D (246, 1)
    if array.ndim == 1:
        array = array.reshape(-1, 1)

    # If the array is Transposed (e.g., shape is (1, 246)), flip it to (246, 1)
    if array.shape[0] != n_neurons and array.shape[1] == n_neurons:
        array = array.T
    # -----

    # Verify if rows match the number of neurons
    if array.shape[0] == n_neurons:

        # CASE A: It is a single column (Metadata)
        if array.shape[1] == 1:
            data_dict[key] = array.flatten()

        # CASE B: It is a Matrix (Time series like AllResp)
        else:
            # Create names for columns: AllResp_0, AllResp_1...
            temp_cols = [f"{key}_{i}" for i in range(array.shape[1])]
            # Create a temporary dataframe
            df_temp = pd.DataFrame(array, columns=temp_cols)
            # Add to main dictionary
            for col in df_temp.columns:
                data_dict[col] = df_temp[col].values
    else:
        print(f"Skipping '{key}': dimension mismatch {array.shape}")

# 5. Create the final DataFrame
df_final = pd.DataFrame(data_dict)

# Show success
print("Table created successfully!")
print(f"Final shape: {df_final.shape}")
```

# DOSSIER PROFESSIONNEL <sup>(DP)</sup>

## Activité-type 1 Intégration de données

**Exemple n°3** ► Création de jeux de données (datasets) synthétiques pour tester des algorithmes d'analyse

### 1. Décrivez les tâches ou opérations que vous avez effectuées, et dans quelles conditions :

À l'aide des bibliothèques NumPy et Pandas, j'ai généré deux jeux de données synthétiques mimant des enregistrements de l'activité électrique des neurones. L'activité électrique d'un neurone est une succession de potentiels d'action au cours du temps qu'on désigne comme un patron de décharge ou « spike train ». Cela se code comme une série temporelle binaire de 0 et de 1 (0 si le neurone est au repos, 1 s'il émet un *spike*). Du fait de la fréquence d'acquisition standard en électrophysiologie de 20 kHz, on a généré deux jeux de données de 50 000 enregistrements chacun.

Modélisation statistique et structure des classes : Le premier dataset modélise trois classes distinctes de neurones sains.

| Les trois classes de neurones | Leurs formule mathématique                                       |
|-------------------------------|------------------------------------------------------------------|
| Classe 1 (Sporadique)         | Bernoulli périodique<br>$B(0.5) \sim \text{Bernoulli}(0.5)$      |
| Classe 2 ( <u>Bursts</u> )    | Processus par rafales aléatoires<br>$L_k \sim U(5, 20)$          |
| Classe 3 (Toniques)           | Processus rectangulaire quasi périodique<br>$G_k \sim U(35, 50)$ |

Le second intègre ces mêmes classes, mais introduit volontairement une anomalie statistique (*outlier*), ciblant un neurone spécifique (le neurone 31). L'ensemble de ces données a été structuré sous forme de séries temporelles, en y intégrant des variables catégorielles (conditions de contrôle et de stimulation).

Injection stochastique de l'anomalie : Pour modéliser l'activité de base des neurones, nous avons appliqué une fréquence de déclenchement régulière. En revanche, le comportement du neurone aberrant a été modélisé par une distribution de Poisson pour générer des salves de signaux (*bursts*), simulant ainsi de manière réaliste la nature stochastique (aléatoire) des décharges neuronales complexes.



# DOSSIER PROFESSIONNEL (DP)

L'ensemble de ces données a été structuré sous forme de séries temporelles et déséquilibrées, en y intégrant des variables catégorielles (conditions de contrôle et de stimulation).

**Les résultats de la création des jeux de données sont disponibles dans la section Informations complémentaires.**

## 2. Précisez les moyens utilisés :

Python (Numpy, Pandas), Statistiques (Loi de Poisson),

Nom des notebook: exo\_neurone\_v01-09-03-2026 / exo\_neurone\_v02-18-03-2026

Lien du notebook:

<https://colab.research.google.com/drive/1YqCNNsKBIsQ99T0hVjzLB0FqvZoyJZ7P>

<https://colab.research.google.com/drive/15XGjwXFuW751TnnqeG8F8NI1c7fqcLya>

## 3. Avec qui avez-vous travaillé ?

L'ensemble de mon travail a été réalisé durant mon stage, en combinant recherche personnelle et prise d'initiative, réunions de suivi avec mon tuteur, ainsi que des échanges réguliers avec les membres de l'équipe d'accueil. J'ai également sollicité, de manière proactive, mon tuteur et certains collègues afin de surmonter des difficultés techniques spécifiques.

## 4. Contexte

Nom de l'entreprise, organisme ou association ►

*INCI CNRS*

# DOSSIER PROFESSIONNEL <sup>(DP)</sup>

**Chantier, atelier,  
service**

► **CNRS**

**Période d'exercice**

► Du **11/02/202** au **17/06/2026**  
**6**

## 5. Informations complémentaires *(facultatif)*

Premier dataset: dataset\_neurones\_100

Ce jeu de données simule l'activité électrique de 100 neurones sur une période de 50 000 ms, répartie entre une condition « contrôle » et une condition « stimulation ». Il a été conçu pour présenter différents profils de décharge neuronale afin d'évaluer des algorithmes de détection de motifs. Le dataset est composé de trois classes de neurones et ne contient ni valeurs aberrantes (outliers) ni neurones présentant un comportement atypique.

Index

Variables

|   | experience | temps-ms | neurone01 | neurone02 | neurone03 | neurone04 | neurone05 | neurone06 | neurone07 | neurone08 | ... | neurone91 | neurone92 | neurone93 | neurone94 | neurone95 | neurone96 | neurone97 | neurone98 | neurone99 | neurone100 |
|---|------------|----------|-----------|-----------|-----------|-----------|-----------|-----------|-----------|-----------|-----|-----------|-----------|-----------|-----------|-----------|-----------|-----------|-----------|-----------|------------|
| 0 | control    | 0        | 0.0       | 1.0       | 1.0       | 0.0       | 0.0       | 1.0       | 0.0       | 1.0       | ... | 0         | 0         | 0         | 0         | 0         | 0         | 0         | 0         | 0         | 0          |
| 1 | control    | 1        | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | ... | 0         | 0         | 0         | 0         | 0         | 0         | 0         | 0         | 0         | 0          |
| 2 | control    | 2        | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | ... | 0         | 0         | 0         | 0         | 0         | 0         | 0         | 0         | 0         | 1          |
| 3 | control    | 3        | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | ... | 0         | 0         | 1         | 0         | 0         | 0         | 0         | 0         | 0         | 1          |
| 4 | control    | 4        | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | ... | 0         | 0         | 1         | 0         | 0         | 0         | 0         | 0         | 0         | 1          |

5 rows x 102 columns

Mesures

Second dataset: dataset\_neurones\_100\_anormal

Dans ce jeu de données, nous avons introduit le neurone 31, dont l'activité suit une loi de Poisson de paramètre  $\lambda=0,005$ . Ce neurone représente un bruit de fond ou une activité spontanée de faible fréquence. L'objectif de ce jeu de données est de détecter ce neurone en tenant compte de la dimension temporelle des signaux neuronaux.

# DOSSIER PROFESSIONNEL (DP)

| Index      | Variables  |          |           |           |           |           |           |           |           |     |           |           |           |           |           |           |           |           |           |            |
|------------|------------|----------|-----------|-----------|-----------|-----------|-----------|-----------|-----------|-----|-----------|-----------|-----------|-----------|-----------|-----------|-----------|-----------|-----------|------------|
| Unnamed: 0 | experience | temps-ms | neurone01 | neurone02 | neurone03 | neurone04 | neurone05 | neurone06 | neurone07 | ... | neurone91 | neurone92 | neurone93 | neurone94 | neurone95 | neurone96 | neurone97 | neurone98 | neurone99 | neurone100 |
| 0          | 0          | control  | 0         | 1.0       | 0.0       | 0.0       | 1.0       | 0.0       | 1.0       | 1.0 | ...       | 0         | 0         | 0         | 0         | 0         | 0         | 0         | 0         | 0          |
| 1          | 1          | control  | 1         | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | 0.0 | ...       | 0         | 0         | 0         | 0         | 0         | 0         | 0         | 0         | 0          |
| 2          | 2          | control  | 2         | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | 0.0 | ...       | 0         | 0         | 0         | 0         | 0         | 0         | 0         | 0         | 0          |
| 3          | 3          | control  | 3         | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | 0.0 | ...       | 0         | 0         | 0         | 0         | 0         | 0         | 0         | 0         | 0          |
| 4          | 4          | control  | 4         | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | 0.0 | ...       | 0         | 0         | 0         | 0         | 0         | 0         | 0         | 0         | 0          |

5 rows x 103 columns

Mesures

## Description des jeux de données

|                      | Dataset_neurone_100    | Dataset_neurone_100_anomal |
|----------------------|------------------------|----------------------------|
| Nombre de neurones   | 100                    | 100                        |
| Enregistrement       | 50000                  | 50000                      |
| Temps (milliseconde) | 50000                  | 50000                      |
| Temps (second)       | 50                     | 50                         |
| Shape du dataset     | (50.000, 100)          | (50.000, 100)              |
| Classe 1             | neurone1 à neurone30   | neurone1 à neurone30       |
| Classe 2             | neurone31 à neurone60  | neurone32 à neurone60      |
| Classe 3             | neurone61 à neurone100 | neurone61 à neurone100     |
| Anomalie             | Pas d'anomalie         | neurone31                  |

# DOSSIER PROFESSIONNEL (DP)

## Activité-type 2 Analyse Exemple n°1 ► Exploration des datasets

### 1. Décrivez les tâches ou opérations que vous avez effectuées, et dans quelles conditions :

Les datasets neurone\_100 et neurone\_100\_anormal ont été générés puis examinés par des analyses exploratoires pour confirmer la présence de distributions différentes pouvant conduire à des regroupements par classes.


#### Représentation structure tabulaire :

Observation de la binarisation du signal de quelques neurones. On observe la correspondance directe entre l'activité temporelle et le stockage numérique sous forme de 0 et de 1.

| neurone01 | neurone02 | neurone03 | neurone04 | neurone05 | neurone06 | neurone07 | neurone08 | ... | neurone91 | neurone92 | neurone93 | neurone94 | neurone95 | neurone96 | neurone97 | neurone98 | neurone99 | neurone100 |
|-----------|-----------|-----------|-----------|-----------|-----------|-----------|-----------|-----|-----------|-----------|-----------|-----------|-----------|-----------|-----------|-----------|-----------|------------|
| 0.0       | 1.0       | 1.0       | 0.0       | 0.0       | 1.0       | 0.0       | 1.0       | ... | 0         | 0         | 0         | 0         | 0         | 0         | 0         | 0         | 0         | 0          |
| 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | ... | 0         | 0         | 0         | 0         | 0         | 0         | 0         | 0         | 0         | 0          |
| 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | ... | 0         | 0         | 0         | 0         | 0         | 0         | 0         | 0         | 0         | 1          |
| 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | ... | 0         | 0         | 1         | 0         | 0         | 0         | 0         | 0         | 0         | 1          |
| 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | 0.0       | ... | 0         | 0         | 1         | 0         | 0         | 0         | 0         | 0         | 0         | 1          |

#### Représentation graphique d'un seul neurone.

Comme l'illustre la figure ci-dessous, l'activité du neurone02 est visualisée sous forme de pics. Chaque pic correspond à une valeur 1 dans le jeu de données (Dataset\_neurone\_100)



Pour l'analyse j'ai travaillé avec ces deux jeux de données


|                    | Dataset_neurones_100 | Dataset_neurones_100_anormal |
|--------------------|----------------------|------------------------------|
| Nombre de neurones | 100                  | 100                          |
| Enregistrement     | 50000                | 50000                        |

## DOSSIER PROFESSIONNEL <sup>(DP)</sup>

|                      |                        |                        |
|----------------------|------------------------|------------------------|
| Temps (milliseconde) | 50000                  | 50000                  |
| Temps (second)       | 50                     | 50                     |
| Shape du dataset     | (50.000, 100)          | (50.000, 100)          |
| Classe 1             | neurone1 à neurone30   | neurone1 à neurone30   |
| Classe 2             | neurone31 à neurone60  | neurone32 à neurone60  |
| Classe 3             | neurone61 à neurone100 | neurone61 à neurone100 |
| Anomalie             | Pas d'anomalie         | neurone31              |


### Représentation graphique d'un seul neurone du Dataset\_neurones\_100 :

Cette représentation graphique Rasterplot permet de visualiser la distribution de nos données et les différentes classes présentes de le dataset.



### Représentation graphique d'un seul neurone du Dataset\_neurones\_100\_anormal

## DOSSIER PROFESSIONNEL (DP)



Pour l'examen des datasets, j'ai réalisé une segmentation (*clustering*) afin d'identifier de potentielles classes de neurones en fonction des distributions des potentiels d'action.

Pour cela j'ai mis en place :

Des statistiques descriptives pour chaque neurone. J'ai calculé 3 descripteurs : la fréquence moyenne d'activation, la variabilité (écart-type) et la persistance temporelle (probabilité de rester actif à  $t+1$ ). L'image ci-dessous illustre les cinq premiers neurones et leurs statistiques.

|           | mean_activity | std_activity | persistence |
|-----------|---------------|--------------|-------------|
| neurone01 | 0.02430       | 0.153980     | 0.000000    |
| neurone02 | 0.02530       | 0.157036     | 0.000000    |
| neurone03 | 0.02494       | 0.155944     | 0.000000    |
| neurone04 | 0.02458       | 0.154843     | 0.000000    |
| neurone05 | 0.02452       | 0.154658     | 0.000000    |

Une réduction de dimension et clustering : après une étape de normalisation (*StandardScaler*), on a appliqué une **Analyse en Composantes Principales** (PCA) pour visualiser les données, puis l'algorithme K-Means pour regrouper les neurones en trois populations fonctionnelles (sporadiques, *burst*, toniques).

---

## DOSSIER PROFESSIONNEL (DP)

---

---

Une validation : l'analyse du score de silhouette a permis de confirmer la pertinence du nombre de clusters retenus.

L'algorithme K-Means ne prend pas en compte la temporalité des données. Cette approche n'a pas de sens réel, car elle ne tient pas compte de l'aspect séquentielle des données, elle permet d'apprécier la variabilité du dataset et les potentiels regroupements.

Les résultats de l'analyse et les graphiques sont disponibles dans la section Informations complémentaires.

### 2. Précisez les moyens utilisés :

Environnement Python, Pandas, Matplotlib, PCA, K-Means

Bibliothèque principale: Scikit-Learn

Nom des notebooks: exo\_neurone\_v01-09-03-2026 / exo\_neurone\_v02-18-03-2026

Lien du notebook :

<https://colab.research.google.com/drive/1YqCNNsKBIsQ99T0hVjzLB0FqvZoyJZ7P>

<https://colab.research.google.com/drive/15XGjwXFuW751TnnqeG8F8NI1c7fqCLya>

### 3. Avec qui avez-vous travaillé ?

---

## DOSSIER PROFESSIONNEL <sup>(DP)</sup>

L'ensemble de mon travail a été réalisé durant mon stage, en combinant recherche personnelle et prise d'initiative, réunions de suivi avec mon tuteur, ainsi que des échanges réguliers avec les membres de l'équipe d'accueil. J'ai également sollicité, de manière proactive, mon tuteur et certains collègues afin de surmonter des difficultés techniques spécifiques.

### 4. Contexte

Nom de l'entreprise, organisme ou association ►

**INCI CNRS**

Chantier, atelier, service

► **CNRS**

Période d'exercice

► Du 11/02/2026 au 17/06/2026  
6

### 5. Informations complémentaires *(facultatif)*



## Validation et Visualisation du Clustering


Pour garantir la fiabilité de notre segmentation, nous avons utilisé des outils de validation statistique :

- PCA : pour voir si les classes sont bien séparées
- Analyse du score de Silhouette : Cette méthode a été utilisée pour déterminer le nombre optimal de clusters (k). Le pic obtenu à k=3 avec un score de 98% valide scientifiquement la structure de nos données et la pertinence de diviser la population neuronale en trois groupes.
- Algorithme K-Means : J'ai utilisé le K-Means pour classer automatiquement les neurones en fonction de leurs caractéristiques (fréquence, variabilité, persistance). Les trois populations identifiées correspondent aux profils biologiques : Sporadique, Burst et Tonique.
- Réduction de dimension (PCA) : Enfin, j'ai utilisé l'Analyse en Composantes Principales (PCA) pour projeter ces données de haute dimension dans un espace en 2D. Cela permet de visualiser clairement la séparation des trois groupes sous forme de nuages de points colorés.

### Dataset\_neurones\_100

- **K-Means + PCA pour la représentation**

*Analyse du score de Silhouette pour déterminer le nombre optimal de clusters (k). Suggère que la partition en trois groupes est cohérente avec la structure statistique observée dans les données. Les couleurs indiquent les trois populations identifiées par l'algorithme K-Means (Sporadique, Burst, Tonique). J'ai utilisé le K-Means pour classer automatiquement les neurones en 3 groupes, puis la PCA pour projeter ces groupes sur un graphique 2D afin de valider visuellement leur séparation*



# DOSSIER PROFESSIONNEL <sup>(DP)</sup>

## 2. Précisez les moyens utilisés :

Environnement Python; approche statistique: DBSCAN, t-SNE, UMAP, K-NN

Bibliothèques principales: Scikit-Learn

Nom des notebook: exo\_neurone\_v01-09-03-2026 / exo\_neurone\_v02-18-03-2026


Lien du notebook :

<https://colab.research.google.com/drive/1YqCNNsKBIsQ99T0hVjzLB0FqvZoyJZ7P>

<https://colab.research.google.com/drive/15XGjwXFuW751TnnqeG8F8NI1c7fqcLya>

### Dataset\_neurone\_100\_anormal

- K-Means + PCA pour la représentation



On peut observer que K-Means et le PCA permettent de détecter le neurone atypique.

### Activité-type 2 Analyse

Exemple n°2 ► Analyse comparative de clustering et réduction de dimension (DBSCAN, t-SNE, UMAP, K-NN)

1. Décrivez les tâches ou opérations que vous avez effectuées, et dans quelles conditions :

## DOSSIER PROFESSIONNEL (DP)

Afin d'affiner la classification des neurones et de valider la séparation des groupes, on a comparé plusieurs approches de réduction de dimension et de détection par densité. Pour cette analyse j'ai utilisé à nouveau mes éléments de statistiques descriptives décrits dans la section précédente.

- **DBSCAN (Density-Based Spatial Clustering)** : On a implémenté cet algorithme pour identifier des outliers (bruit statistique) dans les signaux neuronaux. Contrairement au K-Means, DBSCAN permet de détecter des neurones isolés qui ne rentrent dans aucune catégorie définie.
- **Visualisation avancée (t-SNE & UMAP)** : Pour mieux comprendre la structure locale et globale des données, on a appliqué les algorithmes t-SNE et UMAP. Ces outils nous ont permis de confirmer que les clusters identifiés par le K-Means étaient bien séparés, même dans un espace non linéaire.
- **Classification supervisée (k-NN)** : Une fois les groupes validés, on a entraîné un modèle k-NN (K-Nearest Neighbors). Ce modèle permet de prédire automatiquement la classe d'un nouveau neurone. J'ai évalué ses performances grâce à un rapport de classification détaillé (Précision, Rappel, F1-score).

### 3. Avec qui avez-vous travaillé ?

L'ensemble de mon travail a été réalisé durant mon stage, en combinant recherche personnelle et prise d'initiative, réunions de suivi avec mon tuteur, ainsi que des échanges réguliers avec les membres de l'équipe d'accueil. J'ai également sollicité, de manière proactive, mon tuteur et certains collègues afin de surmonter des difficultés techniques spécifiques.

### 4. Contexte

Nom de l'entreprise, organisme ou association ►

**INCI CNRS**

Chantier, atelier, service

► **CNRS**

Période d'exercice

► Du **11/02/2026** au **17/06/2026**  
**6**

### 5. Informations complémentaires (facultatif)


### Dataset\_neurone\_100

- **Détection de densité (DBSCAN) :**

*La méthode de détection de densité DBSCAN a permis d'identifier les régions de forte densité dans l'espace latent ainsi que les points isolés considérés comme du bruit ou des valeurs aberrantes (outliers). Les résultats obtenus sont cohérents avec ceux observés à l'aide de l'algorithme K-Means.*

*Il convient toutefois de souligner que DBSCAN repose exclusivement sur des critères de densité. L'algorithme n'exploite aucune information relative à la nature des neurones ou à leur comportement physiologique. Dans l'espace latent, il regroupe uniquement les observations selon leur proximité locale et la densité de leur voisinage.*

*Par conséquent, les clusters identifiés par DBSCAN ne correspondent pas nécessairement aux classes biologiques de neurones définies lors de la génération du jeu de données.*




- **Visualisation non-linéaire (t-SNE & UMAP) :** Afin de mieux appréhender la structure complexe des données, on a utilisé des techniques de réduction de dimensions non linéaires, notamment **t-SNE** et **UMAP**.

## DOSSIER PROFESSIONNEL <sup>(DP)</sup>

Ces méthodes nous ont permis de projeter les données dans un espace de plus faible dimension pour en faciliter la visualisation. La représentation obtenue avec *t*-SNE met en évidence trois groupes bien distincts, correspondant aux populations de neurones sporadiques, burst et toniques.

En revanche, la projection obtenue avec UMAP montre une séparation moins nette entre les groupes. Cette différence peut s'expliquer par les propriétés propres à chaque méthode : *t*-SNE privilégie la séparation locale des points, tandis qu'UMAP cherche davantage à préserver la structure globale des données.



- **Classification supervisée (k-NN)** : Une fois les groupes validés, on a entraîné un modèle *k*-NN (*k*-Nearest Neighbors). En utilisant un *split train/test* et une normalisation rigoureuse, on a obtenu un modèle capable de prédire automatiquement le type de neurone avec une précision élevée.

## DOSSIER PROFESSIONNEL <sup>(DP)</sup>


|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| 0            | 1.00      | 1.00   | 1.00     | 7       |
| 1            | 1.00      | 1.00   | 1.00     | 6       |
| 2            | 1.00      | 1.00   | 1.00     | 7       |
| accuracy     |           |        | 1.00     | 20      |
| macro avg    | 1.00      | 1.00   | 1.00     | 20      |
| weighted avg | 1.00      | 1.00   | 1.00     | 20      |

### Dataset\_neurone\_100\_anormal



- *Visualisation non-linéaire (t-SNE & UMAP) : Le t-SNE parvient à bien séparer les classes dans l'espace réduit, tandis que l'UMAP montre une séparation moins nette. Cela suggère que la structure locale des données est mieux capturée par le t-SNE dans ce cas précis, alors que l'UMAP préserve davantage la structure globale, ce qui peut conduire à un chevauchement des classes.*

## DOSSIER PROFESSIONNEL (DP)



- **K-NN**

|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| 0            | 1.00      | 1.00   | 1.00     | 6       |
| 1            | 1.00      | 1.00   | 1.00     | 7       |
| 2            | 1.00      | 1.00   | 1.00     | 7       |
| accuracy     |           |        | 1.00     | 20      |
| macro avg    | 1.00      | 1.00   | 1.00     | 20      |
| weighted avg | 1.00      | 1.00   | 1.00     | 20      |

**Évaluation du Modèle : Classification Parfaite (Précision 1.00)** Le classifieur k-NN a atteint une précision de 100 % sur l'ensemble de test. Bien qu'un score aussi parfait soit rare sur des données réelles bruitées, il est ici justifié par plusieurs facteurs clés :

**Séparabilité élevée des clusters :** Comme nous l'avons visualisé précédemment dans les espaces latents du PCA, les groupes fonctionnels (Sporadique, Burst, Tonique) sont linéairement séparables et distincts.

Étant donné que les étiquettes cibles ont été générées par l'algorithme K-Means en utilisant le même espace de caractéristiques, le modèle k-NN a réussi à capturer parfaitement les frontières de décision établies lors de la phase non-supervisée.

**Conclusion :** Le modèle est extrêmement fiable pour catégoriser de nouveaux enregistrements neuronaux dans le cadre de ce protocole expérimental spécifique.



## Activité-type 2 Analyse

### Exemple n°3 ► Modélisation générative par Deep Learning (Beta-VAE & Transformers) avec Keras


#### 1. Décrivez les tâches ou opérations que vous avez effectuées, et dans quelles conditions :

**Un VAE (Variational Autoencoder)** est une architecture de Deep Learning appartenant à la famille des modèles génératifs. Contrairement à un auto-encodeur classique qui compresse les données d'entrée en un point fixe unique, le VAE compresse les données sous forme d'une distribution de probabilité (définie par une moyenne et un écart-type) au sein d'un espace géométrique restreint appelé l'espace latent.

**Qu'est-ce que l'espace latent ?** C'est un espace géométrique abstrait où le modèle projette les caractéristiques essentielles et cachées des données d'entrée. Au lieu de manipuler des milliers de points de nos séries temporelles, cet espace réduit la dimension du signal. Dans notre projet, cet espace est configuré en deux dimensions (2D) : les comportements neuronaux similaires s'y regroupent naturellement pour former des clusters visibles, tandis que les anomalies (comme le neurone 31) sont rejetées à la périphérie, facilitant ainsi le diagnostic géométrique.

L'architecture se compose traditionnellement de deux sous-réseaux principaux articulés autour de cet espace via une étape charnière :

- **L'Encodeur** : Il prend en entrée les séries temporelles complexes de décharges neuronales « spike trains » à haute dimension et les compresse en calculant les paramètres statistiques de la distribution (la moyenne et l'écart-type) destinés à structurer l'espace latent.
- **L'Astuce de Reparamétrisations** (Reparameterization Trick) : Étape intermédiaire essentielle entre l'encodeur et l'espace latent. L'échantillonnage direct depuis une distribution étant une opération aléatoire non dérivable, elle bloquerait l'algorithme de rétropropagation du gradient (Backpropagation). Cette astuce permet d'introduire un bruit extérieur pour rendre le système calculable et permettre l'apprentissage du réseau.
- **Le Décodeur** : En phase d'entraînement, il prend ce point vectoriel échantillonné dans l'espace latent pour tenter de reconstruire le signal d'origine le plus fidèlement possible. (À noter qu'en production, ce décodeur n'est pas utilisé : seule la position dans l'espace latent 2D nous sert à isoler l'anomalie).



On a conçu et entraîné un modèle de Deep Learning de type Variational Autoencoder (VAE) pour extraire les caractéristiques intrinsèques des signaux neuronaux de manière non supervisée. L'objectif était de projeter la dynamique temporelle complexe des 100 neurones dans un espace latent en 2D.

Pour développer ce VAE, je me suis appuyé sur des travaux antérieurs librement disponibles et réutilisables, notamment le tutoriel de détection d'anomalies dans les séries temporelles proposé par Keras :

[https://keras.io/examples/timeseries/timeseries\\_anomaly\\_detection/](https://keras.io/examples/timeseries/timeseries_anomaly_detection/)

Ce tutoriel a servi de base méthodologique pour la conception et l'implémentation du modèle, qui a ensuite été adapté aux spécificités des signaux neuronaux étudiés dans ce travail.

**Architecture du modèle :** Le réseau utilise des couches de Convolution 1D pour capturer les motifs temporels locaux et un mécanisme de Self-Attention (Transformer) pour modéliser les dépendances à long terme.

- **Régularisation (Beta-VAE) :** Pour garantir un espace latent bien structuré, on a implémenté une variante Beta-VAE (beta=0.001). Cela permet de forcer le modèle à apprendre des représentations déconnectées et significatives.
- **Extraction de signatures latentes :** Une fois le modèle entraîné, nous avons utilisé l'encodeur pour projeter chaque neurone dans un espace de dimension 2. Le calcul des centroïdes par neurone nous ont permis de visualiser une séparation nette des populations (Sporadique, Burst, Tonique), confirmant que l'IA a appris d'elle-même à distinguer les comportements biologiques sans étiquetage préalable.

## DOSSIER PROFESSIONNEL <sup>(DP)</sup>

- **Détection d'anomalies** : Le modèle a également permis d'isoler le « Neurone 31 » comme une anomalie, car sa distribution de Poisson ne présentait aucun motif répétitif identifiable par les couches d'attention, générant ainsi une forte erreur de reconstruction.

**Les résultats de l'analyse et les graphiques sont disponibles dans la section Informations complémentaires.**

### 2. Précisez les moyens utilisés :

Python, Numpy, Réseaux de neurones (CNN, Attention), Beta-VAE.

Bibliothèque principale: Keras core (la nouvelle version découplée de Keras, qui peut fonctionner sans TensorFlow par défaut)

Nom des notebook: exo\_neurone\_v01-09-03-2026 / exo\_neurone\_v02-18-03-2026

Lien du notebook :

<https://colab.research.google.com/drive/1YqCNNsKBIsQ99T0hVjzLB0FqvZoyJZ7P>

<https://colab.research.google.com/drive/15XGjwXFuW751TnnqeG8F8NI1c7fqcLya>

### 3. Avec qui avez-vous travaillé ?

L'ensemble de mon travail a été réalisé durant mon stage, en combinant recherche personnelle et prise d'initiative, réunions de suivi avec mon tuteur, ainsi que des échanges réguliers avec les membres de l'équipe d'accueil. J'ai également sollicité, de manière proactive, mon tuteur et certains collègues afin de surmonter des difficultés techniques spécifiques.

### 4. Contexte

Nom de l'entreprise, organisme ou association ►

**INCI CNRS**

## DOSSIER PROFESSIONNEL <sup>(DP)</sup>

Chantier, atelier,  
service

► CNRS

Période d'exercice


► Du 11/02/2026 au 17/06/2026  
6

### 5. Informations complémentaires *(facultatif)*

Résultat VAE:


#### Dataset\_neurones\_100

- *Projection des 100 neurones dans l'espace latent en 2D du VAE. On observe une séparation nette des populations apprise de manière non-supervisée par le modèle.*



- *Évolution de la fonction de perte (MSE) durant l'entraînement du modèle VAE, démontrant la convergence du réseau.*

## DOSSIER PROFESSIONNEL <sup>(DP)</sup>



- Extrait de l'architecture hybride CNN-Attention implémentée sous Keras.

MODÈLE VAE COMPLET  
Model: "VAE\_Neuronal"

| Layer (type)                   | Output Shape   | Param # | Connected to                               |
|--------------------------------|----------------|---------|--------------------------------------------|
| input_layer_1 (InputLayer)     | (None, 50, 1)  | 0       | -                                          |
| conv1d_2 (Conv1D)              | (None, 50, 32) | 128     | input_layer_1[0]...                        |
| max_pooling1d_1 (MaxPooling1D) | (None, 25, 32) | 0       | conv1d_2[0][0]                             |
| attention_1 (Attention)        | (None, 25, 32) | 0       | max_pooling1d_1[...<br>max_pooling1d_1[... |
| concatenate_1 (Concatenate)    | (None, 25, 64) | 0       | max_pooling1d_1[...<br>attention_1[0][0]   |
| flatten_1 (Flatten)            | (None, 1600)   | 0       | concatenate_1[0]...                        |
| dense_3 (Dense)                | (None, 2)      | 3,202   | flatten_1[0][0]                            |
| dense_4 (Dense)                | (None, 2)      | 3,202   | flatten_1[0][0]                            |
| sampling_1 (Sampling)          | (None, 2)      | 0       | dense_3[0][0],<br>dense_4[0][0]            |
| dense_5 (Dense)                | (None, 800)    | 2,400   | sampling_1[0][0]                           |
| reshape_1 (Reshape)            | (None, 25, 32) | 0       | dense_5[0][0]                              |
| up_sampling1d_1 (UpSampling1D) | (None, 50, 32) | 0       | reshape_1[0][0]                            |
| conv1d_3 (Conv1D)              | (None, 50, 1)  | 97      | up_sampling1d_1[...                        |

Total params: 9,029 (35.27 KB)  
Trainable params: 9,029 (35.27 KB)  
Non-trainable params: 0 (0.00 B)

Dataset\_neurones\_100\_anormal

- *Détection d'anomalie / événement rare*


La figure ci-dessous illustre la projection des caractéristiques compressées par l'encodeur du Beta-VAE dans un espace latent bidimensionnel (défini par les dimensions latentes  $z$ -mean 0 et  $z$ -mean 1). Cette visualisation met en évidence la séparation des différents profils neuronaux et permet d'analyser plus facilement les comportements atypiques au sein du jeu de données :

Le modèle parvient à regrouper de manière totalement non supervisée les signatures temporelles complexes en trois clusters distincts et parfaitement séparés dans l'espace. Chaque cluster correspond à un type d'activité neuronale physiologique standard :

- **Le groupe "Tonique" (en jaune)** : Situé à l'extrême dynamique supérieure droite (coordonnées approximatives :  $z_0 \approx 1.0$  ;  $z_1 \approx 1.6$ ).
- **Le groupe "Burst" (en vert/cyan)** : Positionné dans la partie inférieure centrale (coordonnées approximatives :  $z_0 \approx 0.3$  ;  $z_1 \approx -0.7$ ).
- **Le groupe "Sporadique" (en violet)** : Localisé dans la zone inférieure gauche (coordonnées approximatives :  $z_0 \approx -0.3$  ;  $z_1 \approx 0.0$ ).

**Isolation géométrique de l'anomalie (Le cas du neurone N31)** : L'élément le plus remarquable de cette simulation est la position du neurone 31 (marqué par la croix rouge 'Target: Neuron(Outlier)'). Bien qu'il partage initialement la même base de signal que les neurones sains du groupe Sporadique, le modèle a détecté l'anomalie induite par la distribution stochastique de Poisson (les rafales de signaux ou bursts pathologiques).

Au lieu d'être intégré au cluster violet, le neurone N31 est nettement repoussé à la périphérie (coordonnées approximatives :  $z_0 \approx -0.37$  ;  $z_1 \approx 0.55$ ). Il se situe en dehors des frontières de distribution de toutes les classes saines, ce qui constitue une déviation statistique flagrante.



- *Raison pour lesquelles le neurone31 s'éloigne des autres :*
  - Absence de structure temporelle : le Neurone 31 suit une loi de Poisson et les autres ont un rythme de 20ms.
  - Difficulté de Compression pour le VAE: cherche à compresser les données dans un espace de 2D en apprenant des patrons répétition. Pour le Neurone 31, il n'y a aucun motif à apprendre.
  - Signature Latente Unique: Dans l'espace latent, les neurones ayant des comportements similaires se regroupent (clusters). Le Neurone 31, n'ayant aucune corrélation temporelle avec les autres.

**Conclusion :** Le VAE ne parvient pas à encoder ce neurone de la même manière que les autres, ce qui se traduit par une position isolée dans l'espace latent et un score d'anomalie élevé.

Activité-type 3

Visualisation

Exemple n°1 ►

Visualisation exploratoire avec Matplotlib

1. Décrivez les tâches ou opérations que vous avez effectuées, et dans quelles conditions :

## DOSSIER PROFESSIONNEL <sup>(DP)</sup>

Pour visualiser l'activité simultanée des 100 neurones sur 50000 millisecondes, on a conçu un Raster Plot avec Matplotlib. Un raster plot est une représentation courante des spike trains en neuroscience, mais qui se heurte à la massification des données.

Les spikes ou potentiels d'actions sont représentés par une barre verticale en fonction du temps

Malgré l'absence d'interactivité native, cette visualisation globale a permis de confirmer la présence de structures temporelles et de valider visuellement la cohérence des trois groupes de neurones (sporadiques, bursts, toniques) identifiés après par les algorithmes de clustering

**Les graphiques sont disponibles dans la section Informations complémentaires.**

### 2. Précisez les moyens utilisés :

Matplotlib, Pandas, Numpy

Bibliothèque principal: Matplotlib

Nom des notebooks: exo\_neurone\_v01-09-03-2026 / exo\_neurone\_v02-18-03-2026

Lien du notebook :

<https://colab.research.google.com/drive/1YqCNNsKBIsQ99T0hVjzLB0FqvZoyJZ7P>

<https://colab.research.google.com/drive/15XGjwXFuW751TnnqeG8F8NI1c7fqcLya>

### 3. Avec qui avez-vous travaillé ?



## DOSSIER PROFESSIONNEL <sup>(DP)</sup>

L'ensemble de mon travail a été réalisé durant mon stage, en combinant recherche personnelle et prise d'initiative, réunions de suivi avec mon tuteur, ainsi que des échanges réguliers avec les membres de l'équipe d'accueil. J'ai également sollicité, de manière proactive, mon tuteur et certains collègues afin de surmonter des difficultés techniques spécifiques.


### 4. Contexte

|                                                 |   |               |               |
|-------------------------------------------------|---|---------------|---------------|
| Nom de l'entreprise, organisme ou association ► |   | INCI CNRS     |               |
| Chantier, atelier, service                      | ► | Neuroscience  |               |
| Période d'exercice                              | ► | Du 11/02/2026 | au 17/06/2026 |
|                                                 |   | 6             |               |


### 5. Informations complémentaires (facultatif)

- *Visualization avec matplotlib Raster Plot du dataset Dataset\_neurones\_100*

## DOSSIER PROFESSIONNEL <sup>(DP)</sup>



- *Visualization avec matplotlib Raster Plot du dataset Dataset\_neurones\_100\_anorma, ici on apprécie bien les trois classes et le outliers, malgré l'absence d'interactivité native*



## Activité-type 3 Visualisation

**Exemple n°2** Visualisation exploratoire interactive avec Python  
▶ (Bokeh)

### 1. Décrivez les tâches ou opérations que vous avez effectuées, et dans quelles conditions :

Nous avons enrichi notre analyse avec la bibliothèque Bokeh, un outil spécialisé dans la création de visualisations interactives pour le web. Son utilisation nous a permis de concevoir une interface dynamique et intuitive pour explorer les données en profondeur.

- **Traitement du signal** : Pour faciliter l'analyse visuelle, j'ai implémenté un prétraitement des données brutes permettant de calculer une densité d'activité par neurone.
- **Segmentation visuelle automatique** : Cette interface permet à l'utilisateur d'identifier instantanément les groupes fonctionnels sans analyse manuelle préalable.
- **Interactivité avancée** : En utilisant les capacités de Bokeh, j'ai mis en place des outils de zoom dynamique, de déplacement (*pan*) et de survol (HoverTool) pour obtenir les coordonnées précises (index du neurone et temps exact en millisecondes) de chaque pic d'activité.

**Les graphiques sont disponibles dans la section Informations complémentaires.**

### 2. Précisez les moyens utilisés :

## DOSSIER PROFESSIONNEL (DP)

Python, Bokeh (ColumnDataSource, Segment, HoverTool), Pandas, Numpy.  
liste, fonction conditionnelles.

Bibliothèque principale: Bokeh

Nom des notebooks: exo\_neurone\_v01-09-03-2026 / exo\_neurone\_v02-18-03-2026

Lien du notebook :

<https://colab.research.google.com/drive/1YqCNNsKBIsQ99T0hVjzLB0FqvZoyJZ7P>

<https://colab.research.google.com/drive/15XGjwXFuW751TnnqeG8F8NI1c7fqcLya>

### 3. Avec qui avez-vous travaillé ?

L'ensemble de mon travail a été réalisé durant mon stage, en combinant recherche personnelle et prise d'initiative, réunions de suivi avec mon tuteur, ainsi que des échanges réguliers avec les membres de l'équipe d'accueil. J'ai également sollicité, de manière proactive, mon tuteur et certains collègues afin de surmonter des difficultés techniques spécifiques.

### 4. Contexte

Nom de l'entreprise, organisme ou association ►

**INCI CNRS**

Chantier, atelier, service

► Cours Icam

Période d'exercice


► Du 11/02/2026 au 17/06/2026

### 5. Informations complémentaires (facultatif)

# DOSSIER PROFESSIONNEL (DP)


## 5. Informations complémentaires (facultatif)

- Visualisation en noir et blanc du jeu de données (dataset\_neurone\_100\_anomal)



Visualisation finale en couleur du jeu de données (dataset\_neurone\_100\_anormal)

Ici, on peut apprécier les trois classes ainsi que le neurone anormal





## Activité-type 4 Déploiement

### Exemple n°1 ► D'un VAE en Deep Learning standard à un VAE à Impulsion

#### 1. Décrivez les tâches ou opérations que vous avez effectuées, et dans quelles conditions :

Objectif de ce déploiement est de tester si une approche avec des réseaux de neurones artificiel à impulsions (SNN) peuvent remplacer une approche avec des neurones artificiels standard dans un VAE de classification de série temporelle. Pour cela nous avons décidé de comparer **qualitativement** un VAE réalisé avec PyTorch à un VAE codé par un réseau de neurones à Impulsion (SNN ; spiking neuronal network). Ce type de réseau de neurones artificiels est très utilisé pour analyser des données séquentielles de type série de 0 et 1 ; et sont de plus comme consommant moins d'énergie lors de l'apprentissage.

##### 1. VAE Algorithme Deep Learning Standard, réalisé avec PyTorch.

- Méthodologie : On a implémenté un Auto-encodeur Variationnel (VAE) classique. Ce modèle traite l'activité neuronale comme des vecteurs de données d'intensité continue.
- Capacité de Détection : Le modèle identifie le neurone 31 comme une anomalie. C'est une méthode extrêmement robuste pour détecter des erreurs de mesure ou des bruits techniques (artefacts) (voir figure ci-dessous).

##### 2. Algorithme IA Neuromorphique ,réalisé avec snnTorch

- Méthodologie : On a déployé un réseau de neurones à impulsions (SNN) basé sur le modèle *Leaky Integrate-and-Fire* (LIF). Contrairement au VAE standard, cette approche traite l'information directement de manière temporelle en 0 et 1.
- Capacité de Détection : Le modèle snnTorch met aussi en évidence les 3 classes ainsi que la détection du neurone 31 dans l'espace latent en 2D.

J'ai réalisé une comparaison qualitative des distributions des neurones dans les deux espaces latents (2D) obtenus.

**Conclusion : Le codage d'un VAE à l'aide dans l'une ou l'autre approche (Standard versus SNN) permet dans les deux cas d'obtenir une classification efficace en 3 groupes d'activité et aussi de détecter le neurone 31 au comportement atypique.**


Les résultats de cette analyse sont illustrées par les deux graphiques ci-dessous, dans lesquels on voit clairement que les deux technologies détectent parfaitement le neurone au comportement atypique. On peut également observer l'évaluation de la consommation électrique de chaque technique sous les graphiques. On constate clairement que la

# DOSSIER PROFESSIONNEL <sup>(DP)</sup>

consommation de snnTorch est moins élevée, avec une charge de calcul de seulement 3,13 MB par rapport au VAE PyTorch classique qui monte à 3,81 MB.

Résultats VAE PyTorch

Résultats VAE SNNTorch



Ces travaux préliminaires ont motivé d'utiliser un VAE à Impulsion pour traiter un lot de données 100 fois plus important sur une instance de calcul puissante.

## 2. Précisez les moyens utilisés :

Environnement Python : Google colab

Bibliothèque principale: Pytorch, SNNTorch

Nom des notebooks: BENCHMARK\_PyTorch/SNNTorch.ipynb

Lien du notebook :

[https://colab.research.google.com/drive/1F8eXirerrd5BYTr\\_\\_jMluh8P5L\\_huKnL#scrollTo=hdh71BJwdn8l](https://colab.research.google.com/drive/1F8eXirerrd5BYTr__jMluh8P5L_huKnL#scrollTo=hdh71BJwdn8l)

## DOSSIER PROFESSIONNEL <sup>(DP)</sup>

### 3. Avec qui avez-vous travaillé ?

L'ensemble de mon travail a été réalisé durant mon stage, en combinant recherche personnelle et prise d'initiative, réunions de suivi avec mon tuteur, ainsi que des échanges réguliers avec les membres de l'équipe d'accueil. J'ai également sollicité, de manière proactive, mon tuteur et certains collègues afin de surmonter des difficultés techniques spécifiques.

### 4. Contexte

Nom de l'entreprise, organisme ou association ►

*INCI CNRS*

Chantier, atelier, service

► Icam

Période d'exercice

► Du

au

### 5. Informations complémentaires *(facultatif)*

**Activité-type** 4

*Exemple n° 2* ►

**Déploiement**

Mise en place d'un explorateur PANEL sur Hugging face (application NEURO IA)

1. Décrivez les tâches ou opérations que vous avez effectuées, et dans quelles conditions :



Afin de rendre nos outils d'analyse accessibles aux collaborateurs et aux chercheurs, nous avons conçu et déployé une application web interactive sur la plateforme [Hugging Face Spaces](https://huggingface.co/spaces/KineDS/Benchmark_vae) [https://huggingface.co/spaces/KineDS/Benchmark\\_vae](https://huggingface.co/spaces/KineDS/Benchmark_vae). Cette étape marque la transition du code de recherche vers un outil opérationnel de type "Software as a Service" (SaaS).

- **Framework de l'application** : Nous avons utilisé la bibliothèque Panel (Holoviz) pour transformer nos scripts d'analyse et nos visualisations (Bokeh/Matplotlib) en un tableau de bord (Dashboard) complet. [https://huggingface.co/spaces/KineDS/Benchmark\\_vae](https://huggingface.co/spaces/KineDS/Benchmark_vae). Panel permet de lier efficacement les widgets interactifs (boutons, sliders) aux modèles de Deep Learning sous-jacents.
- **Conteneurisation (Docking) et Hébergement** : L'application a été déployée sur un "Space" Hugging Face en utilisant un environnement Docker et en suite Panel SDK, garantissant que toutes les dépendances techniques (PyTorch, Bokeh, Pandas) sont correctement configurées pour une exécution stable en ligne.
- **Fonctionnalités de l'explorateur** :
  - **Chargement dynamique** : L'utilisateur peut explorer les populations neuronales en temps réel.
  - **Interface intuitive** : Intégration des graphiques interactifs permettant de filtrer les résultats du clustering (Sporadique, Burst, Tonique) et de visualiser les prédictions du modèle VAE.
- **Objectif du déploiement** : Cette mise en place permet de démocratiser l'accès aux modèles d'IA complexes. Un utilisateur non-technicien peut désormais charger un signal neuronal et obtenir une classification automatique sans avoir à manipuler le code source.

**Le résultat de la mise en place l'application NEURO IA est disponibles dans la section Informations complémentaires.**

### 2. Précisez les moyens utilisés :

Python (toutes les bibliothèques utilisées pour l'analyse), Hugging Face, Panel

## DOSSIER PROFESSIONNEL <sup>(DP)</sup>

### 3. Avec qui avez-vous travaillé ?

L'ensemble de mon travail a été réalisé durant mon stage, en combinant recherche personnelle et prise d'initiative, réunions de suivi avec mon tuteur, ainsi que des échanges réguliers avec les membres de l'équipe d'accueil. J'ai également sollicité, de manière proactive, mon tuteur et certains collègues afin de surmonter des difficultés techniques spécifiques.

### 4. Contexte

Nom de l'entreprise, organisme ou association ►

**INCI CNRS**

Chantier, atelier, service ►


Période d'exercice ►

Du 11/02/202 au 17/06/2026  
6

### 5. Informations complémentaires *(facultatif)*

Application NEURO IA

# DOSSIER PROFESSIONNEL (DP)




# DOSSIER PROFESSIONNEL (DP)

Spaces | KineDS/Benchmark\_vea | private | Running | Logs

## Neuro-IA Benchmark PyTorch / SNN Torch


Activité neuronale | Modèle PyTorch | Modèle snnTorch



Spaces | KineDS/Benchmark\_vea | private | Running | Logs

## Neuro-IA Benchmark PyTorch / SNN Torch

Activité neuronale | Modèle PyTorch | Modèle snnTorch



# DOSSIER PROFESSIONNEL <sup>(DP)</sup>

## Activité-type 4

## Déploiement

### Exemple n° 3 ►

Mise en place d'un environnement de calcul distant (Machine Virtuelle & SSH)

### 1. Décrivez les tâches ou opérations que vous avez effectuées, et dans quelles conditions :

On a configuré un environnement de développement hautement performant pour l'entraînement des modèles de Neuro-IA avec Pytorchn SNN Torch et Keras, en séparant l'interface de code de la puissance de calcul.

Cet environnement **I-astro** est une instance de calcul hébergé sur la plateforme BigEST : un environnement Linux Ubuntu sur une machine est équipé de 16 processeurs virtuels (vCPU) reposant sur une architecture AMD EPYC Milan. Cette configuration offre un environnement de calcul parallèle adapté aux traitements intensifs. La mémoire vive allouée à la machine s'élève à 62 Go de RAM ; et dispose par ailleurs d'un accélérateur matériel de type GPU NVIDIA L40S, basé sur l'architecture Ada Lovelace, doté d'environ 46 Go de mémoire dédiée. Pour déployer ma solution j'ai mis en place :

- **Connexion Distant (Tunnel SSH)** : On a mis en place un accès sécurisé via le protocole SSH pour piloter une Machine Virtuelle (VM) hébergée sur un serveur distant. Cela permet d'utiliser des ressources GPU/CPU supérieures à celles d'un ordinateur local.
- **VS Code Remote Development** : On a utilisé l'extension *Remote - SSH* de Visual Studio Code. Cette configuration permet de coder directement sur la machine distante avec le confort de l'interface locale (édition de fichiers, terminal, gestionnaire Git).
- **Gestion de l'environnement avec UV** : Pour la gestion des bibliothèques, on a utilisé UV (un gestionnaire de paquets Python ultra-rapide écrit en Rust). Il remplace « pip » et « conda », permettant d'installer les dépendances (PyTorch, snnTorch) en quelques secondes et de garantir la reproductibilité de l'environnement via un fichier de verrouillage (*uv.lock*).
- **Workflow Jupyter** : On a intégré des notebooks Jupyter directement dans VS Code, connectés au noyau (*kernel*) de la machine virtuelle pour l'exploration de données lourdes en temps réel.
- **Test sur un traitement de données avec un VAE à Impulsion**

Les étapes de ce déploiement sont illustrés dans la section suivante.

### 2. Précisez les moyens utilisés :

## DOSSIER PROFESSIONNEL <sup>(DP)</sup>

**Outils** : Terminal SSH, VS Code, Gestionnaire de paquets UV.

**Environnement** : Machine Virtuelle Linux.

### 3. Avec qui avez-vous travaillé ?

L'ensemble de mon travail a été réalisé durant mon stage, en combinant recherche personnelle et prise d'initiative, réunions de suivi avec mon tuteur, ainsi que des échanges réguliers avec les membres de l'équipe d'accueil. J'ai également sollicité, de manière proactive, mon tuteur et certains collègues afin de surmonter des difficultés techniques spécifiques.

### 4. Contexte

Nom de l'entreprise, organisme ou association ►

**INCI CNRS**

Chantier, atelier, service



Période d'exercice



Du 11/02/202 au 17/06/2026

6

### 5. Informations complémentaires (facultatif)

## DOSSIER PROFESSIONNEL (DP)

Dans notre machine, nous avons souhaité aller plus loin en augmentant le nombre de neurones, passant de 100 à 1 000 neurones sur 50 000 enregistrements. L'objectif était d'augmenter le jeu de données, d'introduire davantage de neurones présentant des comportements atypiques et de les détecter. Cette analyse nous a permis d'exploiter un volume de données plus important et de traiter des séquences de manière plus rapide et plus efficace.


Grâce à cette approche, nous avons pu enrichir notre jeu de données et améliorer la détection des neurones atypiques. Le graphique ci-dessous illustre la distribution des 1000 neurones et le résultat obtenu pour la détection de ces neurones atypiques à l'aide du VAE (Variational Autoencoder).

- *Graphique rasterplot pour la visualisation de la distribution par classes des 1000 neurone du jeu de données*



Le graphique qui suit montre les résultats de la détection du VAE sur l'ensemble de notre jeu de données. On observe qu'il parvient à parfaitement détecter les 10 neurones au comportement atypique (représentés par les croix rouges). De plus, l'algorithme regroupe les neurones sains en trois grandes familles distinctes : les Sporadiques (en violet), les Toniques (en jaune) et les Bursts (en vert).

# DOSSIER PROFESSIONNEL (DP)



C'est deux images ci-dessous illustre mon environnement de travail dans la machine virtuel I-astro.

```
main.py U • Welcome Spike_train_Pytorch_snnTorch.ipynb X neurones.csv U classification_r...
biosim > Spike_train_Pytorch_snnTorch.ipynb > ...
Generate + Code + Markdown | Run All Restart Clear All Outputs Jupyter Variables ...

c='purple', alpha=0.6, s=100, label='Neurones SNN')

# Exemple : mettre en évidence un neurone particulier (par ex. le 31e)
if num_neurons > 30:
    plt.scatter(neuron_centroids[30, 0], neuron_centroids[30, 1],
               c='red', marker='X', s=300, label='Outlier Target (N31)')

plt.title("Espace latent snnTorch (Spiking VAE)")
plt.xlabel("Dim Z1")
plt.ylabel("Dim Z2")
plt.legend()
plt.show()


[ ]

... Début entraînement snnTorch...
Époque 0 | Loss SNN: 0.0195

PROBLEMS 2 OUTPUT DEBUG CONSOLE TERMINAL PORTS 1 JUPYTER
petitjean@iastro:~/MITIenvHP$ source /home/petitjean/MITIenvHP/.venv/bin/activate
○ (mitienvhp) petitjean@iastro:~/MITIenvHP$
```



# DOSSIER PROFESSIONNEL (DP)



## Titres, diplômes, CQP, attestations de formation

(facultatif)

| Intitulé     | Autorité ou organisme            | Date                                    |
|--------------|----------------------------------|-----------------------------------------|
| Cliquez ici. | Cliquez ici pour taper du texte. | Cliquez ici pour sélectionner une date. |
| Cliquez ici. | Cliquez ici pour taper du texte. | Cliquez ici pour sélectionner une date. |
| Cliquez ici. | Cliquez ici pour taper du texte. | Cliquez ici pour sélectionner une date. |
| Cliquez ici. | Cliquez ici pour taper du texte. | Cliquez ici pour sélectionner une date. |
| Cliquez ici. | Cliquez ici pour taper du texte. | Cliquez ici pour sélectionner une date. |

## DOSSIER PROFESSIONNEL <sup>(DP)</sup>

|              |                                  |                                         |
|--------------|----------------------------------|-----------------------------------------|
| Cliquez ici. | Cliquez ici pour taper du texte. | Cliquez ici pour sélectionner une date. |
| Cliquez ici. | Cliquez ici pour taper du texte. | Cliquez ici pour sélectionner une date. |
| Cliquez ici. | Cliquez ici pour taper du texte. | Cliquez ici pour sélectionner une date. |
| Cliquez ici. | Cliquez ici pour taper du texte. | Cliquez ici pour sélectionner une date. |

---

## DOSSIER PROFESSIONNEL <sup>(DP)</sup>

---

---

### Déclaration sur l'honneur

---

Je soussigné(e) ***Kine Diagne, DIOP GUEYE***,  
déclare sur l'honneur que les renseignements fournis dans ce dossier sont exacts et  
que je suis l'auteur(e) des réalisations jointes.

Fait à ***Strasbourg***

le ***02/06/2026***

pour faire valoir ce que de droit.

Signature :



## DOSSIER PROFESSIONNEL <sup>(DP)</sup>

### Documents illustrant la pratique professionnelle

*(facultatif)*

| Intitulé                         |
|----------------------------------|
| Cliquez ici pour taper du texte. |
|                                  |
|                                  |
|                                  |
|                                  |
|                                  |
|                                  |
|                                  |
|                                  |
|                                  |

## ANNEXES

(Si le RC le prévoit)

### Code du VAE Keras

#### 1. Code du encoder

```
# Define input dimensions
timesteps = train.shape[1]
features = train.shape[2]
latent_dim = 2

# Input layer
inputs = keras.Input(shape=(timesteps, features))

# Temporal feature extraction
x = layers.Conv1D(32, 3, padding="same", activation="relu")(inputs)
x = layers.MaxPooling1D(2)(x)

# Self-attention mechanism (TRANSFORMERS)
attention = layers.Attention()([x, x])

# Combine convolution and attention outputs
x = layers.Concatenate()([x, attention])

# Flatten representation
x = layers.Flatten()(x)

# Latent distribution parameters
z_mean = layers.Dense(latent_dim)(x)
z_log_var = layers.Dense(latent_dim)(x)
```

#### 2. Paramétrisation

```
class Sampling(layers.Layer):
    """Uses (z_mean, z_log_var) to sample z, the vector encoding a digit."""

    def call(self, inputs):
        z_mean, z_log_var = inputs

        # Reparameterization trick
        batch = keras.ops.shape(z_mean)[0]
        dim = keras.ops.shape(z_mean)[1]
        epsilon = keras.random.normal(shape=(batch, dim))
        z = z_mean + keras.ops.exp(0.5 * z_log_var) * epsilon

        # --- BETA-VAE ADJUSTMENT ---
        # We introduce beta to prevent "Posterior Collapse"
        # 0.001 helps the model prioritize reconstruction over regularisation
        beta = 0.001

        kl_loss = -0.5 * keras.ops.mean(
            1 + z_log_var - keras.ops.square(z_mean) - keras.ops.exp(z_log_var)
        )

        # Apply beta weight to the KL divergence loss
        self.add_loss(beta * kl_loss)

        return z

# Implementation in the model flow
z = Sampling()([z_mean, z_log_var])
```

### 3. Décodeur

```
# Decoder network
decoder_inputs = layers.Dense((timesteps // 2) * 32, activation="relu")(z)

a = layers.Reshape((timesteps // 2, 32))(decoder_inputs)

a = layers.UpSampling1D(2)(a)
# Upsampling déploie les caractéristiques apprises sur l'axe du temps
# Reconstruct original signal
# Nous utilisons une fonction d'activation Sigmoid sur la dernière couche de convolution.
# Comme nos signaux d'entrée ont été normalisés entre 0 et 1 (MinMax) ou centrés,
# la sigmoïde garantit que la reconstruction respecte la plage de valeurs du signal biologique d'origine.
outputs = layers.Conv1D(1, 3, padding="same")(a)
# Define VAE model
vae = keras.Model(inputs, outputs, name="VAE_Neuronal")
```

